

Kompresja danych EKG z użyciem sztucznej sieci neuronowej typu MLP

Kacper Wojtowicz

Gracjan Adamus

Dominik Godek

29 kwietnia 2026

Streszczenie

W sprawozdaniu opisano projekt kompresji jednowymiarowych przebiegów EKG z użyciem autoenkodera opartego na wielowarstwowym perceptronie. Zadanie polegało na nauczaniu sieci neuronowej, która odwzorowuje wektor 187 próbek pojedynczego uderzenia serca do krótszej reprezentacji latentnej, a następnie rekonstruuje przebieg wejściowy. Do eksperymentów wykorzystano zbiór *ECG Heartbeat Categorization Dataset* z portalu Kaggle, przygotowany na podstawie baz MIT-BIH Arrhythmia Database i PTB Diagnostic ECG Database. Zbadano kilka wymiarów warstwy wąskiego gardła i wyznaczono zależność pomiędzy stopniem kompresji a jakością odtworzenia sygnału. Wyniki autoenkodera MLP porównano z metodą PCA, traktowaną jako liniowy punkt odniesienia.

Spis treści

1	Cel i zakres projektu	3
2	Dane wejściowe	3
2.1	Opis zbioru	3
2.2	Preprocessing	4
3	Autoenkoder MLP	6
3.1	Idea autoenkodera	6
3.2	Architektura	6
3.3	Stopień kompresji	6
4	Uczenie modelu	7
4.1	Funkcja celu	7
4.2	Parametry treningu	7
5	Metryki jakości rekonstrukcji	8
5.1	RMSE i MAE	8
5.2	PRD i PRDN	8
5.3	SNR i wskaźnik jakości	9

6	Wyniki eksperymentów	9
6.1	Porównanie MLP i PCA	9
6.2	Przykładowe rekonstrukcje	12
6.3	Analiza klas	13
7	Procedura eksperymentalna	15
8	Wnioski	15

1 Cel i zakres projektu

Celem projektu było opracowanie i przetestowanie koncepcji kompresji przebiegów EKG przy użyciu sztucznej sieci neuronowej. Rozważany system miał działać dwukierunkowo:

- jako kompresor, czyli enkoder przekształcający sygnał EKG do krótszego wektora cech,
- jako dekompresor, czyli dekodek rekonstruuujący sygnał z reprezentacji skompresowanej.

Przyjęto, że pojedynczy rekord danych jest wektorem:

$$\mathbf{x} = [x_1, x_2, \dots, x_{187}] \in [0, 1]^{187}.$$

Autoenkoder generuje reprezentację latentną:

$$\mathbf{z} = f_{\theta}(\mathbf{x}) \in \mathbb{R}^K,$$

gdzie K oznacza wymiar wąskiego gardła. Dekoder odtwarza sygnał:

$$\hat{\mathbf{x}} = g_{\phi}(\mathbf{z}).$$

Wartość K decyduje o sile kompresji. Im mniejsze K , tym większy stopień kompresji, ale zwykle także większy błąd rekonstrukcji.

2 Dane wejściowe

2.1 Opis zbioru

Źródłem danych był zbiór Kaggle *ECG Heartbeat Categorization Dataset* [1]. Zbiór ten zawiera przetworzone sygnały uderzeń serca pochodzące z publicznych baz MIT-BIH Arrhythmia Database oraz PTB Diagnostic ECG Database. Artykuł Kachuee, Fazeli i Sarrafzadeh [2] opisuje użycie tych danych w kontekście klasyfikacji uderzeń EKG. MIT-BIH jest jedną z klasycznych baz odniesienia dla analizy arytmii [3].

W projekcie wykorzystano część MIT-BIH, rozdzieloną na zbiór treningowo-walidacyjny oraz niezależny zbiór testowy. Dane mają formę tabelaryczną, w której każdy rekord odpowiada jednemu uderzeniu serca:

- 187 kolejnych próbek amplitudy sygnału EKG,
- jedna etykieta klasy rytmu, używana wyłącznie w analizie wyników.


Etykieta nie była używana do uczenia autoenkodera, ponieważ zadanie jest zadaniem rekonstrukcji, nie klasyfikacji. Etykiety wykorzystano jedynie do analizy jakości rekonstrukcji w poszczególnych klasach.

Tabela 1: Rozmiar wykorzystanych zbiorów danych.

Zbiór	Liczba rekordów	Probki sygnału	Etykiety
treningowy	87554	187	1
testowy	21892	187	1

Tabela 2: Rozkład klas w części MIT-BIH.

Zbior	Klasa	Nazwa	Liczba	Udział [%]
treningowy	0	N	72471	82.77
treningowy	1	S	2223	2.54
treningowy	2	V	5788	6.61
treningowy	3	F	641	0.73
treningowy	4	Q	6431	7.35
testowy	0	N	18118	82.76
testowy	1	S	556	2.54
testowy	2	V	1448	6.61
testowy	3	F	162	0.74
testowy	4	Q	1608	7.35



Rysunek 1: Niezbalansowany rozkład klas w zbiorze treningowym i testowym.

2.2 Preprocessing

Wykonany preprocessing obejmował:


1. wczytanie rekordów EKG ze zbioru treningowego i testowego,
2. oddzielenie 187 kolumn sygnału od kolumny etykiety,

3. sprowadzenie próbek do spójnej reprezentacji numerycznej,
4. potraktowanie etykiet jako informacji pomocniczej do późniejszej analizy klas,
5. wydzielenie części walidacyjnej ze zbioru treningowego,
6. przygotowanie par uczących $(\mathbf{x}, \mathbf{y})$, ponieważ autoenkoder uczy się odtwarzać własne wejście.

Sygnały w plikach Kaggle są już znormalizowane do przedziału $[0, 1]$ i doprowadzone do stałej długości 187 próbek. W wielu rekordach końcowe próbki mają wartość zero, co oznacza dopełnienie krótszych segmentów. Z tego powodu przeprowadzono analizę przybliżonej długości niezerowej części sygnału. Wyniki przedstawiono w tabeli 3 oraz na rysunku 2.

Tabela 3: Statystyki szacowanej długości niezerowej części sygnału.

Zbior	Srednia	Odch. std.	Min	Mediana	Max
treningowy	111.69	27.46	17	109	187
testowy	111.42	27.44	10	108	187



Rysunek 2: Histogram szacowanej długości sygnału przed końcowym zero-paddingiem.

Dopełnienie zerami jest istotne dla kompresji, ponieważ model może nauczyć się bardzo dobrze odtwarzać końcowe fragmenty zawierające same zera. Dlatego w interpretacji wyników uwzględniono nie tylko MSE, ale także metryki względne, takie jak PRD i SNR.

3 Autoenkoder MLP

3.1 Idea autoenkodera

Autoenkoder jest siecią neuronową uczoną w trybie nienadzorowanym lub samonadzorowanym. Wejściem i celem uczenia jest ten sam obiekt. Model składa się z dwóch części:

- enkodera f_θ , który redukuje wymiar danych,
- dekodera g_ϕ , który rekonstruuje dane wejściowe.

Jeżeli wymiar reprezentacji latentnej K jest mniejszy od wymiaru wejścia, model musi nauczyć się zwięzłego opisu najważniejszych cech sygnału. Takie podejście jest klasycznym zastosowaniem autoenkoderów opisanym w literaturze uczenia głębokiego [4].

3.2 Architektura

Zastosowano autoenkoder typu MLP, czyli sieć w pełni połączoną. Dla każdego badanego wymiaru K model miał tę samą część wejściową i wyjściową, a zmieniał się jedynie rozmiar warstwy latentnej. W eksperymencie właściwym użyto warstw:

$$187 \rightarrow 2048 \rightarrow 1024 \rightarrow 512 \rightarrow 256 \rightarrow K$$

w enkoderze oraz symetrycznego dekodera:

$$K \rightarrow 256 \rightarrow 512 \rightarrow 1024 \rightarrow 2048 \rightarrow 187.$$

W warstwach ukrytych zastosowano funkcję aktywacji ReLU. W warstwie wyjściowej użyto funkcji sigmoidalnej, ponieważ dane wejściowe są znormalizowane do zakresu $[0, 1]$.

Z punktu widzenia kompresji najważniejsze jest to, że środkowa warstwa K stanowi jedyną informację przekazywaną z enkodera do dekodera. W praktycznej interpretacji można ją traktować jako skompresowany opis uderzenia EKG. Jeżeli K jest małe, model musi pominąć część szczegółów i zachować jedynie cechy najbardziej przydatne do rekonstrukcji. Jeżeli K jest duże, w reprezentacji latentnej mieści się więcej informacji, ale maleje korzyść wynikająca z kompresji.

3.3 Stopień kompresji

Stopień kompresji zdefiniowano jako:

$$CR = \frac{187}{K}.$$

Dla małych wartości K otrzymuje się bardzo silną kompresję. Przykładowo dla $K = 2$ reprezentacja ma tylko dwie liczby, więc formalny stopień kompresji wynosi 93,5. Dla $K = 96$ kompresja jest słabsza, ale model dysponuje znacznie większą przestrzenią do zapisania kształtu sygnału.

W eksperymentach sprawdzono wartości:

$$K \in \{2, 4, 8, 16, 32, 64, 96\}.$$

4 Uczenie modelu

4.1 Funkcja celu

Model uczono minimalizując średni błąd kwadratowy:

$$\mathcal{L}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{1}{187} \sum_{i=1}^{187} (x_i - \hat{x}_i)^2.$$

Jest to naturalna funkcja celu dla rekonstrukcji sygnału, ponieważ silnie karze większe odchylenia amplitudy.


4.2 Parametry treningu

Do uczenia wykorzystano:

- optymalizator Adam,
- współczynnik uczenia 10^{-3} ,
- maksymalnie 80 epok,
- batch size 2048,
- podział walidacyjny 15% ze zbioru treningowego,
- GPU CUDA oraz mixed precision AMP.

Tabela 4: Podsumowanie przebiegu uczenia autoenkoderów MLP.

K	Epoki	Najl. MSE train	Najl. MSE val	Epoka
2	80	0.004413	0.004443	70
4	80	0.001773	0.001994	74
8	80	0.001332	0.001440	77
16	80	0.001638	0.001750	80
32	80	0.001153	0.001272	80
64	80	0.001266	0.001398	78
96	80	0.001207	0.001292	80



Rysunek 3: Walidacyjny błąd MSE w kolejnych epokach dla różnych wartości K .

5 Metryki jakości rekonstrukcji

Do oceny jakości rekonstrukcji użyto kilku metryk, ponieważ pojedynczy wskaźnik nie opisuje w pełni zachowania modelu.

5.1 RMSE i MAE

RMSE określa pierwiastek ze średniego błędu kwadratowego:

$$RMSE = \sqrt{\frac{1}{N \cdot 187} \sum_{n=1}^N \sum_{i=1}^{187} (x_{n,i} - \hat{x}_{n,i})^2}.$$

MAE mierzy średnią wartość bezwzględną błędu:

$$MAE = \frac{1}{N \cdot 187} \sum_{n=1}^N \sum_{i=1}^{187} |x_{n,i} - \hat{x}_{n,i}|.$$

5.2 PRD i PRDN

PRD, czyli *Percentage Root-mean-square Difference*, zdefiniowano jako:

$$PRD = 100 \cdot \sqrt{\frac{\sum (\mathbf{x} - \hat{\mathbf{x}})^2}{\sum \mathbf{x}^2 + \varepsilon}}.$$

PRDN jest wersją z centrowaniem sygnału:

$$PRDN = 100 \cdot \sqrt{\frac{\sum (\mathbf{x} - \bar{\mathbf{x}})^2}{\sum (\mathbf{x} - \bar{\mathbf{x}})^2 + \varepsilon}}.$$

Metryki PRD i PRDN są użyteczne w analizie sygnałów biomedycznych, ponieważ pokazują błąd względem energii sygnału.

5.3 SNR i wskaźnik jakości

Stosunek sygnału do szumu obliczono jako:

$$SNR = 10 \log_{10} \frac{\sum \mathbf{x}^2 + \varepsilon}{\sum (\mathbf{x} - \hat{\mathbf{x}})^2 + \varepsilon}.$$

Dodatkowo wprowadzono prosty wskaźnik jakości kompresji:

$$QS = \frac{CR}{PRD}.$$

Wysoka wartość QS oznacza korzystny kompromis: duży stopień kompresji przy względnie małym błędzie rekonstrukcji.


6 Wyniki eksperymentów

6.1 Porównanie MLP i PCA


Jako metodę odniesienia wykorzystano PCA. PCA dla danego K znajduje najlepszą liniową podprzestrzeń minimalizującą błąd rekonstrukcji w sensie MSE. Autoenkoder MLP jest metodą nieliniową, ale nie ma gwarancji znalezienia globalnego optimum. Porównanie obu metod pozwala ocenić, czy nieliniowy model neuronowy uzasadnia swoją większą złożoność.

Tabela 5: Metryki rekonstrukcji na zbiorze testowym.


Metoda	K	CR	PRD	PRDN	SNR [dB]	RMSE	MAE	QS
MLP autoencoder	2	93.500	23.568	33.530	12.554	0.06706	0.03375	3.9673
PCA	2	93.500	43.952	62.531	7.140	0.12507	0.07194	2.1273
MLP autoencoder	4	46.750	15.867	22.574	15.990	0.04515	0.02147	2.9464
PCA	4	46.750	38.209	54.361	8.357	0.10872	0.05920	1.2235
MLP autoencoder	8	23.375	13.497	19.203	17.395	0.03841	0.01818	1.7319
PCA	8	23.375	32.652	46.454	9.722	0.09291	0.05051	0.7159
MLP autoencoder	16	11.688	14.790	21.042	16.601	0.04208	0.02003	0.7902
PCA	16	11.688	24.542	34.917	12.202	0.06983	0.03675	0.4762
MLP autoencoder	32	5.844	12.620	17.955	17.979	0.03591	0.01694	0.4631
PCA	32	5.844	15.406	21.918	16.246	0.04384	0.02150	0.3793
MLP autoencoder	64	2.922	13.237	18.833	17.564	0.03767	0.01775	0.2207
PCA	64	2.922	7.115	10.123	22.956	0.02025	0.00954	0.4107
MLP autoencoder	96	1.948	12.743	18.129	17.895	0.03626	0.01717	0.1529
PCA	96	1.948	4.123	5.866	27.696	0.01173	0.00526	0.4725




Rysunek 4: Zależność PRD od stopnia kompresji.



Rysunek 5: Zależność RMSE od stopnia kompresji.



Rysunek 6: Zależność SNR od stopnia kompresji.



Rysunek 7: Zależność wskaźnika $QS = CR/PRD$ od stopnia kompresji.


Wyniki pokazują oczekiwany kompromis pomiędzy stopniem kompresji a jakością rekonstrukcji. Przy bardzo małym K model musi zachować jedynie najbardziej dominujące cechy kształtu uderzenia. Wraz ze wzrostem K rekonstrukcja staje się dokładniejsza, lecz maleje formalny stopień kompresji. Warto zauważyć, że najlepsza wartość samego PRD nie musi oznaczać najlepszego rozwiązania praktycznego, ponieważ model z dużym K może poprawiać rekonstrukcję kosztem słabej kompresji.

Porównanie z PCA jest szczególnie istotne. PCA jest silną bazą odniesienia dla danych, których zmienność można dobrze opisać liniowo. Autoenkoder MLP może osiągać


przewagę w wariantach o silniejszej kompresji, ponieważ nieliniowość pozwala lepiej odwzorować ograniczoną różnorodność kształtów EKG. Dla większych wartości K PCA może być konkurencyjne lub lepsze, co wynika z jej zamkniętej, stabilnej procedury optymalizacji liniowej. Oznacza to, że samo użycie sieci neuronowej nie gwarantuje automatycznie lepszej kompresji dla każdego poziomu K .

6.2 Przykładowe rekonstrukcje

Rysunki 8 i 9 przedstawiają przykładowe odtworzenia przebiegów. Na wykresach widać, że autoenkoder poprawnie zachowuje globalne położenie i główny kształt zespołu QRS, natomiast mniejsze elementy morfologii, takie jak drobne oscylacje lub szczegóły końcowej części sygnału, są wygładzane. Jest to typowe dla kompresji stratnej uczonej przez minimalizację MSE.




Rysunek 8: Przykładowe rekonstrukcje MLP dla $K = 8$.




Rysunek 9: Przykładowe rekonstrukcje MLP dla $K = 16$.

6.3 Analiza klas

Chociaż autoenkoder nie był uczony do klasyfikacji, etykiety klas pozwalają sprawdzić, czy jakość rekonstrukcji jest podobna dla różnych typów uderzeń. W zbiorze występuje silna nierównowaga klas: klasa normalna jest dominująca, a klasy rzadsze mają znacznie mniej przykładów. Taka struktura danych może powodować, że model lepiej odtwarza typowe kształty, a gorzej nietypowe lub rzadkie morfologie.



Rysunek 10: Rozkład PRD dla poszczególnych klas MIT-BIH, $K = 8$.



Rysunek 11: Rozkład PRD dla poszczególnych klas MIT-BIH, $K = 16$.

Analiza pudełkowa PRD pozwala stwierdzić, że błąd rekonstrukcji nie jest jednorodny pomiędzy klasami. Jest to zgodne z intuicją: autoenkoder optymalizuje średnią stratę na wszystkich rekordach, a więc klasy liczniejsze mają większy wpływ na gradient. W zastosowaniu medycznym należałoby rozważyć ważenie próbek, oversampling klas rzadkich albo osobne modele dla wybranych typów przebiegów.

7 Procedura eksperymentalna

Eksperyment zaplanowano tak, aby odpowiedzieć na dwa pytania: jak silnie można skompresować pojedyncze uderzenie EKG oraz jak szybko pogarsza się jakość rekonstrukcji przy zmniejszaniu wymiaru reprezentacji latentnej. Procedura składała się z następujących etapów:

- przygotowanie danych i oddzielenie sygnałów od etykiet klas,
- wyznaczenie zbioru walidacyjnego służącego do obserwacji procesu uczenia,
- nauczanie osobnego autoenkodera dla każdej wartości K ,
- rekonstrukcja wszystkich przykładów ze zbioru testowego,
- obliczenie metryk jakości rekonstrukcji,
- porównanie wyników MLP z metodą PCA przy tych samych wartościach K ,
- analiza wykresów jakości, przykładów rekonstrukcji oraz rozkładów błędów w klasach.

Ważnym założeniem było zachowanie uczciwego porównania pomiędzy wariantami. Dla każdej wartości K użyto tej samej architektury poza rozmiarem wąskiego gardła, tego samego podziału danych oraz tych samych metryk. Dzięki temu obserwowane różnice można interpretować głównie jako skutek zmiany stopnia kompresji, a nie jako efekt innej konfiguracji eksperymentu.

Wyniki analizowano na trzech poziomach. Pierwszy poziom stanowiły zagregowane miary błędów w tabeli metryk. Drugi poziom obejmował wykresy zależności CR od PRD, RMSE, SNR i QS , które pokazują globalny kompromis między kompresją i jakością. Trzeci poziom polegał na wizualnej ocenie przykładowych rekonstrukcji oraz sprawdzeniu, czy błąd rozkłada się podobnie dla różnych klas MIT-BIH.

8 Wnioski

Zrealizowany projekt potwierdza, że autoenkoder MLP może zostać użyty jako stratny kompresor przebiegów EKG. Enkoder redukuje 187-próbkowy sygnał do wektora latentnego o wymiarze K , a dekodery odtwarza przebieg z tej reprezentacji. Najważniejszym parametrem sterującym kompromisem jest wymiar wąskiego gardła.

Dla małych wartości K uzyskuje się bardzo wysoki stopień kompresji, ale rekonstrukcja traci część szczegółów. Dla większych wartości K błąd maleje, lecz maleje też korzyść kompresji. W praktycznym zastosowaniu nie należy wybierać modelu wyłącznie na podstawie najniższego PRD; należy uwzględnić także CR , QS oraz wymagania konkretnego systemu, np. transmisji danych z urządzenia przenośnego.

Porównanie z PCA pokazuje, że liniowa metoda odniesienia jest bardzo silna, zwłaszcza dla większych wymiarów reprezentacji. Autoenkoder MLP jest uzasadniony przede wszystkim wtedy, gdy zależy nam na nieliniowej kompresji i akceptujemy koszt treningu oraz strojenia hiperparametrów. Dalsze prace mogłyby obejmować autoenkodery konwolucyjne 1D, ważenie klas, inne funkcje straty oraz ocenę zachowania modelu na dłuższych, ciągłych fragmentach EKG.

Literatura

- [1] Shayan Fazeli, *ECG Heartbeat Categorization Dataset*, Kaggle, <https://www.kaggle.com/datasets/shayanfazeli/heartbeat>.
- [2] M. Kachuee, S. Fazeli, M. Sarrafzadeh, *ECG Heartbeat Classification: A Deep Transferable Representation*, arXiv:1805.00794, 2018.
- [3] G. B. Moody, R. G. Mark, *The impact of the MIT-BIH Arrhythmia Database*, IEEE Engineering in Medicine and Biology Magazine, 20(3), 45–50, 2001.
- [4] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.